

## 1. 概述

若两类训练样本是线性可分的，SVM 即找到一个超平面，使得两类最靠近的样本点的距离都达到最大，该平面就是最优分界面。最优边界上的样本称之为“支持向量”


对线性可分的两类问题  $\left\{ \vec{x}^p, d^p \right\}_{p=1}^N, d^p \in \{-1, 1\}$ ，找到  $\vec{\omega}, b$  满足

$$\begin{cases} \vec{\omega}^\top \vec{x}^p + b \geq 1 & d^p = 1 \\ \vec{\omega}^\top \vec{x}^p + b \leq -1 & d^p = -1 \end{cases}$$

## 2. 最优平面的支撑向量

### 2.1. 样本到最优分界面的距离

假设最优分界面已经找到，记为  $\vec{\omega}_0^\top \vec{x} + b_0 = 0$ ， $\vec{\omega}_0$  和  $b_0$  为最优分界面的法向量和偏差  
令  $\vec{x}^p$  为任一样本，且  $\vec{x}^p$  在最优分界面的投影为  $\vec{x}_p^l$



则可知  $\vec{x}^p = \vec{x}_p^l + r \left( \frac{\vec{\omega}_0}{\|\vec{\omega}_0\|} \right)$   $r: \vec{x}^p$  到最优分界面的距离

令  $g(\vec{x}) = \vec{\omega}_0^\top \vec{x} + b_0$ ，则可知

$$g(\vec{x}^p) = \vec{\omega}_0^\top \left( \vec{x}_p^l + r \left( \frac{\vec{\omega}_0}{\|\vec{\omega}_0\|} \right) \right) + b_0 = \vec{\omega}_0^\top \vec{x}_p^l + b_0 + r \frac{\vec{\omega}_0^\top \vec{\omega}_0}{\|\vec{\omega}_0\|} = r \frac{\|\vec{\omega}_0\|^2}{\|\vec{\omega}_0\|} = r \|\vec{\omega}_0\|$$

$\because \vec{x}_p^l$  在最优分界面上  $\therefore \vec{\omega}_0^\top \vec{x}_p^l + b_0 = 0$

则可知  $r = \frac{g(\vec{x}^p)}{\|\vec{\omega}_0\|}$ ，即为支撑向量到最优分界面的距离

最优边界  $g(\vec{x}^p) = 1$  和  $g(\vec{x}^p) = -1$  之间距离为  $\rho = 2r = \frac{2}{||\vec{\omega}_0||}$

故可知要使  $\rho \rightarrow \max \Rightarrow ||\vec{\omega}_0|| \rightarrow \min \Rightarrow \sqrt{\vec{\omega}^\top \vec{\omega}} \rightarrow \min \Rightarrow \vec{\omega}^\top \vec{\omega} \rightarrow \min$

## 2.2. 寻找最优分界面

$$\begin{cases} \vec{\omega}^\top \vec{x}^p + b \geq 1 & d^p = 1 \\ \vec{\omega}^\top \vec{x}^p + b \leq -1 & d^p = -1 \end{cases} \Rightarrow d^p (\vec{\omega}^\top \vec{x}^p + b) \geq 1 \quad (d^p \text{ 的取值是编码方式})$$

求最优分界面时应在约束条件  $d^p (\vec{\omega}^\top \vec{x}^p + b) \geq 1$  下求  $\vec{\omega}^\top \vec{\omega}$  的最小值，即使目标函数 J 最小，作拉格朗日函数得

$$J(\vec{\omega}, b, \vec{\alpha}) = \frac{1}{2} \vec{\omega}^\top \vec{\omega} - \sum_{p=1}^N \alpha_p (d^p (\vec{\omega}^\top \vec{x}^p + b) - 1) \quad \vec{\alpha} = (\alpha_1, \dots, \alpha_N)^\top$$

求导并令其等于 0 得

$$\begin{aligned} \frac{\partial J}{\partial \vec{\omega}} &= \vec{\omega} - \sum_{p=1}^N \alpha_p (d^p \vec{x}^p) = 0 \Rightarrow \vec{\omega} = \sum_{p=1}^N \alpha_p (d^p \vec{x}^p) \\ \frac{\partial J}{\partial b} &= \sum_{p=1}^N \alpha_p d^p = 0 \Rightarrow \sum_{p=1}^N \alpha_p d^p = 0 \end{aligned}$$

将上述结果代入 J 中得到新的目标函数

$$\begin{aligned} Q(\vec{\alpha}) &= \frac{1}{2} \sum_{p=1}^N \alpha_p d^p \vec{x}^{p\top} \cdot \sum_{q=1}^N \alpha_q d^q \vec{x}^q - \sum_{p=1}^N \alpha_p d^p \left( \sum_{q=1}^N \alpha_q d^q \vec{x}^q \right)^\top \vec{x}^p - \sum_{p=1}^N \alpha_p d^p b + \sum_{p=1}^N \alpha_p \\ &\because \sum_{p=1}^N \alpha_p d^p = 0 \quad \therefore \sum_{p=1}^N \alpha_p d^p b = b \sum_{p=1}^N \alpha_p d^p = 0 \\ \text{故化简得 } Q(\vec{\alpha}) &= \sum_{p=1}^N \alpha_p - \frac{1}{2} \sum_{p=1}^N \sum_{q=1}^N \alpha_p \alpha_q d^p d^q \vec{x}^{p\top} \vec{x}^q \end{aligned}$$

$$\text{令 } \frac{\partial Q(\vec{\alpha})}{\partial \alpha_p} = 0, \text{ 得到 } N \text{ 个方程, 进一步求得 } \alpha_p, \text{ 得出 } \vec{\omega}_0 = \sum_{p=1}^N \alpha_p d^p \vec{x}^p$$

当  $\alpha_p > 0$  时，对应的样本为支撑向量

$$\text{在 } d^s (\vec{\omega}_0^\top \vec{x}^s + b_0) = 1 \text{ 中代入支撑向量, 可求得 } b_0 = \frac{1}{d^s} - \vec{\omega}_0^\top \vec{x}^s$$

## 2.3. 非线性支撑向量机

### 2.3.1. 概述

对于线性不可分的样本作非线性变换，变成线性可分，在映射的空间内采用前述的方法

$$\text{映射后的最优分界面 } \vec{\omega}_0^\top \vec{\phi}(\vec{x}) + b_0 = 0 \quad \vec{\omega}_0 = \sum_{p=1}^N \alpha_p d^p \vec{\phi}(\vec{x}^p)$$

$$g(\vec{x}) = \text{sgn} \left( \sum_{p=1}^N \alpha_p d^p \vec{\phi}(\vec{x}^p)^\top \vec{\phi}(\vec{x}) + b_0 \right) = \text{sgn} \left( \sum_{p=1}^N \alpha_p d^p K(\vec{x}^p, \vec{x}) + b_0 \right)$$

$$\text{核函数 } K(\vec{x}^p, \vec{x}) = \vec{\phi}(\vec{x}^p)^\top \vec{\phi}(\vec{x}) = \sum_j \phi_j(\vec{x}^p) \phi_j(\vec{x})$$

- $K(\vec{x}^p, \vec{x}) = K(\vec{x}, \vec{x}^p)$
- 最优分界面  $\sum_{p=1}^N \alpha_p d^p K(\vec{x}^p, \vec{x}) + b_0 = 0$

常用的核函数如下：

- $K(\vec{x}, \vec{x}^p) = \exp \left\{ -\frac{\|\vec{x} - \vec{x}^p\|^2}{2\sigma^2} \right\}$

- $K(\vec{x}, \vec{x}^p) = (\vec{x}^\top \vec{x}^p + 1)^M$

- sigmoid 函数

### 2.3.2. 算法

已知输入样本  $\vec{x}^p, p = 1, 2, \dots, N$  和对应的输出  $d^p \in \{-1, 1\}$ ，非线性变换  $\vec{\phi}(\vec{x}^p)$

- 在约束条件  $\sum_{p=1}^N \alpha_p d^p = 0$  及  $\alpha_p \geq 0$  的条件下，使目标函数

$$Q(\vec{\alpha}) = \sum_{p=1}^N \alpha_p - \frac{1}{2} \sum_{p=1}^N \sum_{q=1}^N \alpha_p \alpha_q d^p d^q K(\vec{x}^p, \vec{x}^q)$$

由  $\frac{\partial Q(\vec{\alpha})}{\partial \vec{\alpha}} = 0$ ，求得  $\alpha_1, \alpha_2, \dots, \alpha_N$

- 计算  $\vec{\omega}_0 = \sum_{p=1}^N \alpha_p d^p \vec{\phi}(\vec{x}^p)$   $b_0 = \frac{1}{d^s} - \vec{\omega}_0^\top \vec{\phi}(\vec{x}^s)$
  - 对测试集样本, 求  $K(\vec{x}, \vec{x}^p)$ , 计算  $g(\vec{x}) = \text{sgn}\left(\sum_{p=1}^N d^p \alpha_p K(\vec{x}^p, \vec{x}) + b_0\right)$
- 若  $\begin{cases} g(\vec{x}) = 1 & \vec{x} \in C_1 \\ g(\vec{x}) = -1 & \vec{x} \in C_2 \end{cases}$

例: SVM 求解异或问题

$$\vec{x} = \begin{cases} (-1, -1)^\top & d = -1 \\ (-1, 1)^\top & d = 1 \\ (1, -1)^\top & d = 1 \\ (1, 1)^\top & d = -1 \end{cases} \quad \text{核函数 } K(\vec{x}, \vec{x}^p) = (1 + \vec{x}^\top \vec{x}^p)^2$$

其中  $\vec{x}^p = (x_1^p, x_2^p)^\top$   $\vec{x} = (x_1, x_2)^\top$   $p = 1, 2, 3, 4$

则可知  $K(\vec{x}, \vec{x}^p) = 1 + (x_1^p)^2 x_1^2 + 2x_1^p x_2^p x_1 x_2 + (x_2^p)^2 x_2^2 + 2x_1^p x_1 + 2x_2^p x_2$

$$\vec{\phi}(\vec{x}) = (1, x_1^2, \sqrt{2}x_1x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2)^\top \quad \vec{\phi}(\vec{x}^p) = (1, (x_1^p)^2, \sqrt{2}x_1^p x_2^p, (x_2^p)^2, \sqrt{2}x_1^p, \sqrt{2}x_2^p)^\top$$

故可知

$$[K] = \begin{bmatrix} K(\vec{x}^1, \vec{x}^1) & K(\vec{x}^1, \vec{x}^2) & K(\vec{x}^1, \vec{x}^3) & K(\vec{x}^1, \vec{x}^4) \\ K(\vec{x}^2, \vec{x}^1) & K(\vec{x}^2, \vec{x}^2) & K(\vec{x}^2, \vec{x}^3) & K(\vec{x}^2, \vec{x}^4) \\ K(\vec{x}^3, \vec{x}^1) & K(\vec{x}^3, \vec{x}^2) & K(\vec{x}^3, \vec{x}^3) & K(\vec{x}^3, \vec{x}^4) \\ K(\vec{x}^4, \vec{x}^1) & K(\vec{x}^4, \vec{x}^2) & K(\vec{x}^4, \vec{x}^3) & K(\vec{x}^4, \vec{x}^4) \end{bmatrix} = \begin{bmatrix} 9 & 1 & 1 & 1 \\ 1 & 9 & 1 & 1 \\ 1 & 1 & 9 & 1 \\ 1 & 1 & 1 & 9 \end{bmatrix}$$

$$Q(\vec{\alpha}) = \sum_{p=1}^N \alpha_p - \frac{1}{2} \sum_{p=1}^N \sum_{q=1}^N \alpha_p \alpha_q d^p d^q K(\vec{x}^p, \vec{x}^q)$$

$$\frac{\partial Q}{\partial \alpha_i} = 0 \quad i = 1, 2, 3, 4 \Rightarrow \begin{cases} 9\alpha_1 - \alpha_2 - \alpha_3 - \alpha_4 = 1 \\ -\alpha_1 + 9\alpha_2 + \alpha_3 - \alpha_4 = 1 \\ -\alpha_1 + \alpha_2 + 9\alpha_3 - \alpha_4 = 1 \\ \alpha_1 - \alpha_2 - \alpha_3 + 9\alpha_4 = 1 \end{cases} \Rightarrow \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = \frac{1}{8}$$

$$\vec{\omega}_0 = \sum_{p=1}^N \alpha_p d^p \vec{\phi}(\vec{x}^p) = \left(0, 0, -\frac{1}{\sqrt{2}}, 0, 0\right)^\top$$

$$b_0 = \frac{1}{d^s} - \vec{\omega}_0^\top \vec{\phi}(\vec{x}^s), \text{ 取 } \vec{x}_1 \text{ 计算 } b_0 \text{ 得 } b_0 = 0$$

最优分界面

$$\vec{\omega}_0^\top \vec{\phi}(\vec{x}) + 0 = 0 \Rightarrow \begin{bmatrix} 0 & 0 & -\frac{1}{\sqrt{2}} & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ x_1^2 \\ \sqrt{2}x_1x_2 \\ x_2^2 \\ \sqrt{2}x_1 \\ \sqrt{2}x_2 \end{bmatrix} = 0 \Rightarrow -x_1x_2 = 0$$

最终的  $g(\vec{x}) = \text{sgn}\{-x_1, x_2\}$

$$\text{注: } \vec{\omega}_0^\top \vec{\phi}(\vec{x}) + b_0 = \left( \sum_{p=1}^N \alpha_p d^p \vec{\phi}(\vec{x}^p) \right)^\top \vec{\phi}(\vec{x}) + b_0 = \left( \sum_{p=1}^N \alpha_p d^p \right) K(\vec{x}^p, \vec{x}) + b_0$$

$$b_0 = \frac{1}{d^s} - \vec{\omega}_0^\top \vec{\phi}(\vec{x}^s) = \frac{1}{d^s} - \left( \sum_{p=1}^N \alpha_p d^p \vec{\phi}(\vec{x}^p) \right)^\top \vec{\phi}(\vec{x}^s) = \frac{1}{d^s} - \left( \sum_{p=1}^N \alpha_p d^p \right) K(\vec{x}^s, \vec{x}^p)$$

由此可以看出，只需要知道核函数即可计算结果，无需知道具体的线性变换函数  $\vec{\phi}$